UNIVERSIDAD TORCUATO DI TELLA

# Tutor Socrático EPP

## Registro de Iteraciones

Evaluación de Programas y Proyectos — Maestría en Políticas Públicas

Guadalupe Dorna — gdorna@utdt.edu

*Documento vivo — Última actualización: marzo 2026*

## Qué es este documento

Este documento registra la evolución de las instrucciones del Tutor Socrático, un Gem de Gemini diseñado para que los estudiantes de Evaluación de Programas y Proyectos (EPP) repasen los conceptos clave de cada unidad antes de clase.

Cada versión de las instrucciones se modifica a partir de evidencia concreta: encuestas a estudiantes, observación de transcripciones y testeo propio. El objetivo es documentar qué se cambió, por qué y qué efecto tuvo, para que cualquier persona que continúe este trabajo pueda entender las decisiones tomadas y seguir mejorando.

**Cómo usar este documento:** después de cada ronda de uso con estudiantes, agregar una nueva fila a la tabla de versiones con la fecha, los cambios realizados y la fuente que los motivó (encuesta, transcripción, observación propia). También actualizar la sección de la encuesta si se modifica el formulario.

## Historial de versiones

| Versión | Fecha | Cambios | Fuente |
|---|---|---|---|
| v0 | Feb 2026 | Borrador original. Tutor socrático genérico, 15 interacciones, preguntas de lo general a lo específico, cierre con resumen. Sin restricción estricta al material, sin diagnóstico estructurado, sin reglas de avance. | *Diseño inicial* |
| v1.0 | Mar 2026 | 8 cambios tras testeo del ayudante: fidelidad al material, priorización de conceptos, secuencia intuición-teoría, repreguntas específicas, reformulación, post-respuesta correcta, naturalidad, referencias precisas. | *Testeo interno* |
| v2.0 | Mar 2026 | 6 cambios tras encuesta a estudiantes: extensión máxima 2-4 oraciones, validación mesurada, preguntas no obvias, diagnóstico restringido, correcciones con ejemplos, cierre rediseñado concepto por concepto. | *Encuesta (n=15)* |
| v2.1 | Mar 2026 | Agregada REGLA CRÍTICA: VERIFICAR ANTES DE VALIDAR. El tutor debe verificar internamente que la respuesta sea correcta antes de validarla. Surge de testeo propio donde el tutor validó una respuesta incorrecta con "Exactly" y siguió como si fuera correcta. | *Testeo propio* |

*Los archivos de instrucciones completas por versión son: v0_tutor_socratico_ES.txt, v1.0_tutor_socratico_ES.txt y v2.0_tutor_socratico_ES.txt (v2.1 está en el mismo archivo v2.0 actualizado).*

## Iteración 1: v0 → v1.0

El ayudante probó la v0 en al menos 3 conversaciones con distintos materiales y documentó 8 problemas con sus soluciones.

### Cambios realizados

| Cambio | Descripción |
|---|---|
| **Fidelidad al material** | No introducir autores, aplicaciones, contextos ni ejemplos que no estén explícitamente en el material. |
| **Priorización** | Criterios para elegir conceptos: fundamentales para la lógica de la unidad, supuestos importantes, pasos centrales. Evitar detalles menores. |
| **Intuición-teoría** | Orden: primero significado práctico, después fundamento teórico. Antes las preguntas eran correctas pero malas para abrir conversación. |
| **Repreguntas** | Ante errores, 1-3 repreguntas al error concreto. Antes el tutor corregía rápido o avanzaba. |
| **Reformulación** | Distinguir no saber de no entender la consigna. Si no entiende, reformular más simple. |
| **Post-correcta** | Tras validar, párrafo breve de por qué está bien y dónde verlo en el material. |
| **Naturalidad** | Retomar algo del estudiante, variar transiciones, evitar mecánico. |
| **Referencias** | No inventar números de slide. Preferir referencias por tema. |

### Encuesta diseñada para probar la v1.0

| Pregunta | Formato |
|---|---|
| ¿Cómo te parecieron las preguntas del tutor? | *Simples / Adecuadas / Complejas* |
| ¿Sentiste que el tutor se mantuvo fiel al material? | *Completamente / En general / Poco / Nada* |
| ¿Qué tan útil te resultó el tutor para repasar? | *1 a 5* |
| ¿Qué tan útil te resultó la devolución final? | *1 a 5* |
| Comentarios o sugerencias adicionales | *Texto libre* |

## Iteración 2: v1.0 → v2.0

Se probó la v1.0 con estudiantes de la materia. 15 de ~20 alumnos respondieron la encuesta.

### Resultados de la encuesta

**Utilidad del tutor:** 4.20 / 5

**Utilidad de la devolución:** 3.53 / 5 ← punto débil

**Preguntas:** 13 Adecuadas, 1 Simples, 1 Complejas

**Fidelidad al material:** 10 Completamente, 5 En general

### Comentarios textuales (6 de 15)

- "Que haga preguntas menos obvias para probarte pero en general bien diferenciando conocimientos válidos de conocimientos de la materia."
- "Me pareció muy útil, estaría bueno que dé ejemplos para ilustrar los conceptos."
- "Me da mucho la razón, no creo que mis respuestas hayan sido tan excelentes."
- "Respondía mucho texto. No lo usaría voluntariamente."
- "Estaría bueno que use más fuentes que solo la de la unidad."
- "En las devoluciones me sugirió repasar cosas que no me había preguntado, como si se las hubiera contestado mal."

### Cambios realizados

| Feedback | Cambio |
|---|---|
| *"Me da mucho la razón"* | Validación mesurada, sin elogios efusivos. |
| *"Preguntas menos obvias"* | Priorizar interpretar, no solo recordar. |
| *"Repasar cosas que no me preguntó"* | Diagnóstico solo cubre conceptos discutidos. |
| *"Que dé ejemplos"* | Correcciones ancladas en ejemplo del material. |
| *"Mucho texto"* | Nuevo bloque: 2-4 oraciones por turno máximo. |
| *Devolución 3.53/5* | Cierre rediseñado: concepto por concepto + pregunta de autoevaluación. |

### Cambio adicional: v2.0 → v2.1

Durante testeo propio posterior a los cambios de la encuesta, se detectó un problema crítico: el tutor validó una respuesta incorrecta del estudiante con "Exactly" y siguió la conversación como si fuera correcta. El estudiante tuvo que frenar al tutor y decirle "but I said the opposite".

Las instrucciones ya decían "no valides respuestas incorrectas", pero el modelo las ignoró. La solución fue agregar una sección prominente al inicio de las instrucciones:

**REGLA CRÍTICA: VERIFICAR ANTES DE VALIDAR — Antes de validar CUALQUIER respuesta, verificar internamente que sea correcta según el material. Validar una respuesta incorrecta es el peor error que podés cometer como tutor.**

*Esto ilustra una limitación importante: las instrucciones pueden ser correctas pero el modelo no siempre las sigue. A veces la solución no es cambiar la regla sino hacerla más visible y redundante.*

## Próxima iteración: v2.1 → v3.0

### Preguntas abiertas

- **¿Por qué la devolución tiene baja valoración?** ¿Es genérica, repetitiva, poco accionable?
- **¿Cuántas interacciones están teniendo?** ¿Alcanzan para un diagnóstico rico?
- **¿El límite de extensión mejoró la experiencia?** ¿Se siente ágil o demasiado corto?
- **¿Las preguntas mejoraron?** ¿Siguen siendo obvias o requieren pensar?

### Encuesta propuesta

Misma brevedad (6 preguntas, <2 min) pero recogiendo lo que nos falta.

| Pregunta | Opciones | Qué mide |
|---|---|---|
| ¿Cómo te parecieron las preguntas? | Simples / Adecuadas / Complejas | Dificultad (= v1) |
| ¿Qué tan útil te resultó el tutor para repasar? | 1 a 5 | Utilidad (= v1) |
| ¿La devolución te sirvió para saber qué repasar? | Sí, exactamente / Más o menos / No me sirvió | Accionabilidad (NUEVA) |
| ¿La extensión de las respuestas fue adecuada? | Muy cortas / Adecuadas / Muy largas | Extensión (NUEVA) |
| ¿Qué mejorarías de la devolución del tutor? ¿Es genérica, repetitiva, poco accionable? | Texto libre | Insights |
| Comentarios o sugerencias | Texto libre | Insights |

### Cambios respecto a la encuesta anterior

- Se mantienen: dificultad, utilidad general, comentarios abiertos.
- Se reemplaza: utilidad genérica de la devolución por accionabilidad.
- Se elimina: fidelidad al material (10/15 “Completamente”, poca varianza).
- Se agregan: extensión de respuestas y cantidad de turnos.

### Resultados de la encuesta

- **Utilidad del tutor**: 4.00 / 5 (vs. 4.20 en encuesta anterior)
- **Preguntas**: 6/6 Adecuadas (vs. 13 Adecuadas, 1 Simples, 1 Complejas en la anterior)
- **Extensión de respuestas**: 5 Adecuadas, 1 Muy largas ← el límite de 2-4 oraciones funcionó para la mayoría
- **Accionabilidad de la devolución**: 4 "Sí, exactamente", 2 "Más o menos" ← mejora respecto a la devolución anterior (3.53/5), aunque persisten problemas

## Comentarios textuales

- "Creo que el diagnóstico es muy benevolente, siempre tira como que identifiqué bien o que logré captar el concepto incluso cuando le contestaba 'no sé' a alguna pregunta o le tiraba algo incorrecto a propósito"
- "Esta muy bien."
- "Que devuelva ejemplos prácticos de aplicación estaría bueno."
- "La devolución es buena, repasa cada tema que preguntó y como te fue en cada uno. En mi opinión, tal vez es un poco benévolo con los errores y aunque no haya sido tan clara mi explicación la da como buena. Podría exigirme más rigurosidad."
- "Creo que es un poco complaciente, le cuesta decirte que algo que dijiste esta mal o incompleto. Pero en líneas generales es una buena herramienta."
- "Que las respuestas no sean tan largas."

## Cambios realizados

| Feedback | Cambio |
|---|---|
| "El diagnóstico es muy benevolente" / "complaciente" / "podría exigirme más rigurosidad" (3/6) | Antes de escribir cada entrada, revisar internamente cómo respondió el estudiante. Sí respondió mal, el diagnóstico debe reflejarlo. Frases prohibidas en validación: "bien, pero...", "vas por buen camino", "la idea general está bien". Indicación de ser directo ante errores. |
| "Las preguntas son un poco simples... me encantaría que me haga profundizar con preguntas más incisivas" | Mínimo de preguntas por concepto subido de 2-3 a 3-4. Lógica explícita: intuición, fundamento teórico, conexión/aplicación, y una cuarta para desafiar.. |
| "Que las respuestas no sean tan largas" | Regla de extensión corta extendida al diagnóstico final: máximo 2-3 oraciones por concepto. Formato flexible: no hace falta cubrir los 4 puntos si no aplican todos. |
| Respuestas incompletas tratadas como correctas | Sección "respuesta incompleta" reescrita: "Una respuesta incompleta es una respuesta incompleta. No la trates como correcta." Prohibido "bien, pero..." o "sí, y además..." |
| Conversaciones demasiado cortas en testeo propio | Regla de extensión corta extendida al diagnóstico final: máximo 2-3 oraciones por concepto. Formato flexible: no hace falta cubrir los 4 puntos si no aplican todos. |
| | |

## Encuesta propuesta v3.0

Misma brevedad (6 preguntas, <2 min) pero recogiendo lo que nos falta.

| Pregunta | Opciones | Qué mide |
|---|---|---|
| ¿Cómo te parecieron las preguntas? | Simples / Adecuadas / Complejas | Dificultad (= v1) |

| | | |
|---|---|---|
| ¿Qué tan útil te resultó el tutor para repasar? | 1 a 5 | Utilidad (= v1) |
| Cuando te equivocaste en algo, ¿el tutor te lo señaló claramente? | Sí, exactamente / Más o menos / No | Honestidad (NUEVA) |
| ¿Sentiste que las preguntas se pusieron más difíciles a medida que avanzaba la conversación? | Si, fue subiendo / Se mantuvieron siempre iguales / No, fueron fáciles | Escalamiento (NUEVA) |
| ¿Cuántos turnos tuviste aprox.? | Menos de 10 / 10-15 / Más de 15 | Duración |
| Comentarios o sugerencias | Texto libre | Insights |

*Después de aplicar esta encuesta, agregar una sección “Iteración 3” con el mismo formato: resultados → cambios → nueva versión.*